

桂之瑜

本科生

About

蜀山区高新技术产业开发
区复兴路100号 合肥市 安
徽省 230031 中华人民共
和国

guizhiyu@mail.ustc.edu.c
n

18005859962

00ffcc.tech

后端开发

熟练

Python C Cpp Cython

SQL

前端开发

熟练

PyQt

GPU Kernel开发

熟练

Triton CUDA HIP

硬件开发

熟练

Verilog 嘉立创EDA

会搭服务器

Interests

LLM

LLM Reasoning

LLM 推理优化

线性 LLM 结构设计

LLM 可解释性

具身智能

灵巧手

视触觉传感器

自动驾驶

内河航运自动驾驶、辅助驾驶

Summary

中国科学技术大学 少年班学院 计算机科技英才班 大三在读，GPA：3.85/4.3，排名：26/215。

Projects

Count-R1 · <https://github.com/00ffcc/count-R1/>

03/2025 - 03/2025

在数数任务上复现了Deepseek-R1 ZERO。

切题输入法(AttnInput) · <https://00ffcc.tech/assets/pdf/attninput.pdf>

02/2024 - 02/2025

使用大语言模型增强拼音输入法，负责全部后端模型推理与训练工作，已获得奇绩创投口头投资承诺。

conRWKV · <https://github.com/00ffcc/conRWKV>

01/2025 - 02/2025

首个支持continuous-batching和chunk prefill的高并发RWKV后端推理框架，大幅缩短TTFT，提供了兼容OpenAI格式的api接口。

Education

中国科学技术大学

09/2022 - 06/2026

安徽，合肥

本科 计算机科学与技术专业

Awards

中国科学技术大学RoboGame2023机器人大赛 冠军

中国科学技术大学

负责机器人视觉、定位、通信。

中国科学技术大学人工智能创新应用大赛 冠军

中国科学技术大学信息科学技术学院

单人完成，主要涉及图像语义分割。

RWKV 2025 生态内容征集大赛 银奖

元始智能

单人完成了首个支持continuous-batching的RWKV后端推理框架。

Publications

AttnInput: Advancing Context-Aware Pinyin Input with Efficient Language Model Integration

02/2025

ALC2025在投

使用大语言模型增强拼音输入法，在首字母简拼上达到SOTA性能，同时大幅降低了训练成本。

Experience

浙江蓝城智舸科技有限公司

01/2025 - 02/2025

实习生

参与研发内河新能源船舶的自动驾驶技术